

ОТЧЕТ ПО ПРОЕКТУ

«Предсказание оттока клиентов телеком-компаний»

Задача: бинарная классификация Churn

Данные: 7043 клиента, 21 исходный признак

Модели: Logistic Regression, Random Forest, CatBoost, MLP

ВВЕДЕНИЕ

Цель проекта - построить модель, которая оценивает вероятность оттока клиента телеком-компаний. Работа включает исследовательский анализ данных, обработку пропусков и категориальных признаков, создание дополнительных признаков, обучение трех классических моделей и многослойного перцептрона, подбор гиперпараметров по 5-кратной стратифицированной кросс-валидации, анализ порога классификации и сценарную оценку экономического эффекта retention-кампании.

1. ДАННЫЕ И ИССЛЕДОВАТЕЛЬСКИЙ АНАЛИЗ

В работе используется датасет Telco Customer Churn, содержащий 7043 клиента и 21 исходный признак. Целевая переменная Churn отражает факт ухода клиента и рассматривается как задача бинарной классификации.

1.1. Подготовка данных

Признак TotalCharges изначально имел строковый тип. После преобразования в числовой формат были обнаружены 11 пропусков, все у новых клиентов с tenure = 0. Эти значения были заменены на 0.

Уникальный идентификатор customerID был удалён перед моделированием, так как не несёт полезной информации для прогнозирования.

Категории No internet service и No phone service были сохранены как отдельные значения, поскольку они отличаются по смыслу от обычного No.

1.2. Основные результаты EDA

В выборке около 26,5% клиентов относятся к классу оттока, поэтому для оценки моделей далее используются не только Accuracy, но и Precision, Recall, F1-score и ROC-AUC.

Наиболее заметные различия между ушедшими и оставшимися клиентами связаны со следующими признаками:

- у ушедших клиентов средний tenure ниже: около 18 месяцев против 38 месяцев;
- средний MonthlyCharges выше: около 74,4 против 61,3;
- для Month-to-month доля оттока составляет около 42,7%, для One year - 11,3%, для Two year — 2,8%;
- для Fiber optic доля оттока составляет около 41,9%, для DSL - около 19,0%;
- при оплате через Electronic check доля оттока достигает около 45,3%;
- доля оттока последовательно снижается с увеличением срока обслуживания: от 52,9% для клиентов с tenure 0–6 месяцев до 9,5% для группы 49–72 месяца.

Основные результаты EDA показывают, что наиболее информативными для дальнейшего моделирования являются срок обслуживания, тип контракта, ежемесячные платежи, тип интернет-сервиса и способ оплаты.

2. ПРЕДОБРАБОТКА И КЛАССИЧЕСКИЙ МОДЕЛИ

2.1. Feature Engineering

На основе EDA созданы три дополнительных признака: NumServices - число подключенных дополнительных интернет-услуг; IsNewCustomer - индикатор клиента со сроком обслуживания не более 6 месяцев; AutoPayment - использование автоматического способа оплаты. Числовые признаки масштабировались StandardScaler, категориальные кодировались OneHotEncoder. Предобработка выполнялась внутри Pipeline, что исключает утечку информации между фолдами.

2.2. Кросс-валидация и подбор гиперпараметров

Для сравнения моделей использована StratifiedKFold с 5 фолдами. Основной метрикой выбора служил ROC-AUC, дополнительно рассчитывались Accuracy, Precision, Recall и F1. Для Logistic Regression, Random Forest и CatBoost выполнен GridSearch по гиперпараметрам.

Модель	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.807	0.677	0.524	0.590	0.848
Random Forest	0.774	0.555	0.751	0.638	0.846
CatBoost	0.806	0.670	0.530	0.591	0.851
MLP	0.804	0.660	0.545	0.594	0.847

CatBoost показал максимальный ROC-AUC на кросс-валидации - 0,851. Random Forest выделяется существенно более высоким Recall (0,751) и F1 (0,638), однако имеет более низкий Precision. Это означает, что при стандартном пороге 0,5 он находит больше реально уходящих клиентов ценой большего числа ложных срабатываний.

2.3. Эффект подбора гиперпараметров

Для Random Forest подбор увеличил ROC-AUC с 0,823 до 0,846, то есть на 0,023 абсолютного значения. Для CatBoost ROC-AUC вырос с 0,848 до 0,851; Recall - с 0,517 до 0,530; F1 - с 0,583 до 0,591. Для Logistic Regression подбор не дал заметного прироста ROC-AUC: итоговое значение осталось около 0,848.

3. НЕЙРОННАЯ СЕТЬ MLP

После предобработки данных размер входного вектора составил 33 признака. Для нейросетевой части была использована полносвязная MLP архитектуры $33 \rightarrow 64 \rightarrow 32 \rightarrow 1$.


Первый скрытый слой содержит 64 нейрона и расширяет представление исходных признаков, позволяя модели учитывать нелинейные взаимодействия между ними. Второй скрытый слой уменьшает размерность до 32 нейронов и постепенно сжимает полученное представление перед выходным слоем. Такая архитектура выбрана как достаточно компактная для табличного датасета данного размера: более глубокая сеть здесь не гарантирует улучшения качества и может сильнее переобучаться.

В скрытых слоях используется функция активации ReLU. Для регуляризации применён Dropout: 0,3 после первого скрытого слоя и 0,2 после второго. На выходе используется один нейрон, поскольку решается задача бинарной классификации.

В качестве функции потерь применяется BCEWithLogitsLoss. Она объединяет бинарную кросс-энтропию и сигмоидальное преобразование, поэтому отдельный слой Sigmoid внутри модели не требуется. Оптимизация выполнялась алгоритмом Adam, а обучение проводилось на GPU с использованием CUDA.

3.1. Ранняя остановка

На отдельной validation-выборке максимальный ROC-AUC 0,8488 был достигнут на 7-й эпохе. После первых эпох train ROC-AUC продолжал расти, тогда как validation ROC-AUC переставал улучшаться, а validation loss начинал увеличиваться. Поэтому использован Early Stopping с восстановлением лучших весов.






Рисунок 2 — Динамика функции потерь и ROC-AUC при обучении MLP

3.2. Итоговое качество MLP

На 5-кратной кросс-валидации MLP получила Ассигуру 0,804, Precision 0,660, Recall 0,545, F1 0,594 и ROC-AUC 0,847. Нейросетевая модель показала качество, сопоставимое с классическими алгоритмами, но не превзошла CatBoost по ROC-AUC и Random Forest по Recall/F1.

4. ФИНАЛЬНАЯ ОЦЕНКА И ВЫБОР ПОРОГА

4.1. Результаты на тестовой выборке

После фиксации архитектур и гиперпараметров модели были оценены на независимой тестовой выборке. ROC-AUC оказался практически одинаковым: 0,846 для Logistic Regression и CatBoost и 0,844 для Random Forest и MLP.

Модель	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.803	0.667	0.513	0.580	0.846
Random Forest	0.758	0.531	0.749	0.622	0.844
CatBoost	0.804	0.669	0.519	0.584	0.846
MLP	0.797	0.652	0.505	0.569	0.844




Рисунок 3 — ROC-кривые моделей на тестовой выборке

4.2. Настройка порога классификации

Порог подбирался не по test, а по out-of-fold предсказаниям X_{train} . Для CatBoost максимум $F1 = 0,642$ достигнут при $threshold = 0,34$ (Precision 0,576; Recall 0,726). Для Random Forest максимум $F1 = 0,642$ получен при $threshold = 0,52$ (Precision 0,571; Recall 0,733).

5. БИЗНЕС-ИНТЕРПРИТАЦИЯ

5.1. Проверка зафиксированного порога

После применения заранее выбранных порогов к тестовой выборке CatBoost при threshold 0,34 получил Precision 0,562, Recall 0,727, F1 0,634 и ROC-AUC 0,846. Random Forest при threshold 0,52 получил Precision 0,545, Recall 0,738, F1 0,627 и ROC-AUC 0,844. В качестве основной модели выбран CatBoost: он имеет лучший ROC-AUC по кросс-валидации и после настройки порога сохраняет высокий Recall при немного более высоких Precision и F1 на test.




Рисунок 4 - Зависимость Precision, Recall и F1 от порога классификации

5.2. Сценарный анализ ROI

Для CatBoost с порогом 0,34 на тестовой выборке получено TN = 823, FP = 212, FN = 102 и TP = 272. В retention-кампанию попадают 484 клиента. Поскольку датасет не содержит фактической стоимости предложения и вероятности успешного удержания, экономическая оценка выполнена в виде сценарного анализа.

Успех удержания	Потеря = 300	Потеря = 600	Потеря = 1200
10%	-0.66	-0.33	0.35
20%	-0.33	0.35	1.70
30%	0.01	1.02	3.05

При стоимости retention-предложения 50 условных денежных единиц положительный ROI появляется при разных комбинациях ценности клиента и эффективности удержания. Например, при стоимости потерянного клиента 1200 кампания остается прибыльной уже при 10% успешно удержанных клиентов; при стоимости 600 требуется около 20%.

ЗАКЛЮЧЕНИЕ

Проект показал, что на данном табличном датасете сложная нейросетевая модель не дает преимущества над классическими алгоритмами. Наиболее сбалансированным решением оказался CatBoost. Ключевым практическим результатом стал не только выбор модели, но и настройка порога классификации на out-of-fold предсказаниях: снижение порога CatBoost с 0,5 до 0,34 позволило значительно увеличить Recall при приемлемом Precision. Модель может использоваться как инструмент ранжирования клиентов по риску оттока и формирования целевой аудитории retention-кампаний, а экономическая целесообразность зависит от реальной стоимости контакта и эффективности механики удержания.